

```
In [1]: # package import
import pandas as pd
import re

# Basic Cleaning Text Function
def CleanText(readData):
    # Remove Retweets
    text = re.sub('RT @[\\w_]+: ', '', readData)
    # Remove Mentions
    text = re.sub('@[\\w_]+', '', text)
    # Remove or Replace URL
    text = url_re.sub('URL', text)
    text = re.sub(r"http[s]?://(?:[a-zA-Z][0-9]|[$_.@.&+][!*(\\),]|(?:%[0-9a-fA-F][0-9a-fA-F]))+", ' ', text) # start with ht
    text = re.sub(r"[-a-zA-Z0-9@:%._\+~#={1,256}\.[-a-zA-Z0-9()]{2,6}\b([-a-zA-Z0-9()@:%_\+.~#?&/=]*)", ' ', text) # Don't sta
    # Remove Hashtag
    text = re.sub('[#]+[0-9a-zA-Z_]+', ' ', text)
    # Remove Garbage Words (ex. &lt;, &gt;, etc)
    text = re.sub('[&]+[a-z]+', ' ', text)
    # Remove Numbers (If you want, activate the code)
    text = re.sub(r'\d+', ' ', text)
    #alphabet_regular_expression = re.compile("[A-Za-z ]+")
    text = re.sub(alphabet_regular_expression, "", text)
    # Remove English (If you want, activate the code)
    # text = re.sub('[a-zA-Z]', ' ', text)
    # Remove newline
    text = text.replace('\n', ' ')
    # Remove multi spacing & Reform sentence
    text = ' '.join(text.split())
    return text
```

```
In [2]: # Vietnam Stopwords Load
file_vietnam_stopwords = open("./vietnamese-stopwords.txt", 'r', encoding="utf8")
vietnam_stopwords = []
while True:
    x=file_vietnam_stopwords.readline()
    x=x.replace('\n','')
    vietnam_stopwords.append(x)
    if (x==''):
        break
vietnam_stopwords
```

```
In [3]: from pyvi import ViTokenizer

def preprocessing(readData):
    #### Clean text
    sentence = CleanText(readData)
    sentence = sentence.lower()
    #### Tokenize
    result = ViTokenizer.tokenize(sentence)

    tmp = result.split(' ') #Spilit string into indiviudal terms
    SPECIAL_CHARACTER = list('0123456789%@$.,?+-!;/()""&^:#{|\n\t\'')
    alphabet_regular_expression = re.compile("[^a-zA-Z 0123456789%@$.,?+-!;/()""&^:#{|\n\t\'']+")
    # Remove Stopwords
    for w in vietnam_stopwords:
        for k in tmp:
            if k==w:
                tmp.remove(w)
    # Remove SPECIAL_CHARACTER
    for w in SPECIAL_CHARACTER:
        for k in tmp:
            if k==w:
                tmp.remove(w)
    # Remove non-alphabet words
    tmp1 = []
    for text in tmp:
        #print(str(text))
        text = re.sub(alphabet_regular_expression, "", str(text))
        if (text!='') and (len(text)>1):
            tmp1.append(text)

    return tmp1
print(f"Before preprocessing : ạ Những thông tin trên khiến nhiều người lo lắng về sự lây lan của virus mới này, nhất là với nhữ
ng trường hợp có sức đề kháng kém như người già, phụ nữ mang thai và trẻ nhỏ")

preprocessing("[인론, ạ i a Những 15678 thông tin trên khiến nhiều người lo lắng về sự lây lan của virus mới này, nhất là với n
hững trường hợp có sức đề kháng kém như người già, phụ nữ mang thai và trẻ nhỏ? !")
```

- For Vietnamese, Pyvi was used to tokenize.

- Used stopwords from dictionaries and customed ones.
- Add text normalization codes